Lab 2: Music Genre Classification – CNNs

David Cendejas

Notebook: `lab2.ipynb`

1. Resumen

Se clasifican los 10 géneros de GTZAN (999 canciones; *jazz.00054* está corrupto) a partir de los espectrogramas mel de `images_original`. Se hace una única partición estratificada y barajada 80/20 (799 canciones de train, 200 de test) y **todos los modelos usan exactamente la misma**. Para elegir configuraciones sin tocar el test, el 80% de train se vuelve a dividir 80/20 en train interno (639) y validación (160); la validación decide la configuración y la época de *early stopping*. El test solo se usa una vez por modelo.

Se entrenan: (1) una CNN desde cero explorando profundidad y nº de filtros, (2) ResNet18 preentrenada en ImageNet, como extractor congelado + regresión logística y con fine-tuning completo, y (3) los cinco modelos del Lab 1 sobre `features_30_sec.csv`, reentrenados en la misma partición. Todo se ejecutó en una GPU NVIDIA RTX 3050 con PyTorch y precisión mixta; el notebook completo tarda unos 6 minutos.

2. Task 1 – CNN desde cero

Cada bloque es *Conv 3×3* → *BatchNorm* → *ReLU* → *MaxPool 2×2* y el nº de filtros se duplica en cada bloque. La cabeza es *Global Average Pooling* → Dropout(0.3) → Linear(10), que evita la capa densa enorme y deja pocos parámetros para solo 639 canciones de entrenamiento. La entrada es el espectrograma en escala de grises a 109×168. Se usa Adam (lr 10^{-3}, weight decay 10^{-4}) con *learning rate* en coseno durante 60 épocas, se guarda la mejor época en validación (paciencia 15) y como *data augmentation* se aplica un desplazamiento circular aleatorio en el eje temporal. No se usan flips: invertir el tiempo o las frecuencias no tiene sentido musical.

Se probaron 2, 3, 4 y 5 capas convolucionales con 16 o 32 filtros iniciales (Tabla 1). La profundidad es lo que más importa: con 2 capas el campo receptivo es demasiado pequeño y la red no pasa de 0.53-0.56 en validación, y con 4 capas llega a 0.78. A partir de ahí añadir capas o filtros no mejora: la red de 5 capas y 32 filtros tiene 16 veces más parámetros (1.6M) y saca lo mismo o menos. La mejor configuración por validación es **4 capas / 16 filtros** (99k parámetros, val 0.781), que obtiene **0.780 en test**.

Capas conv	Filtros iniciales	Parámetros	Mejor época	Val acc	Tiempo (s)
4	16	98922	47	0.781	12.974
4	32	391370	33	0.769	17.692
5	16	395882	55	0.769	12.497
5	32	1575114	49	0.769	27.905
3	32	94410	43	0.731	18.600
3	16	24170	45	0.681	12.989
2	32	19658	29	0.556	17.690
2	16	5226	50	0.525	18.917

Tabla 1. Configuraciones exploradas (ordenadas por accuracy de validación).

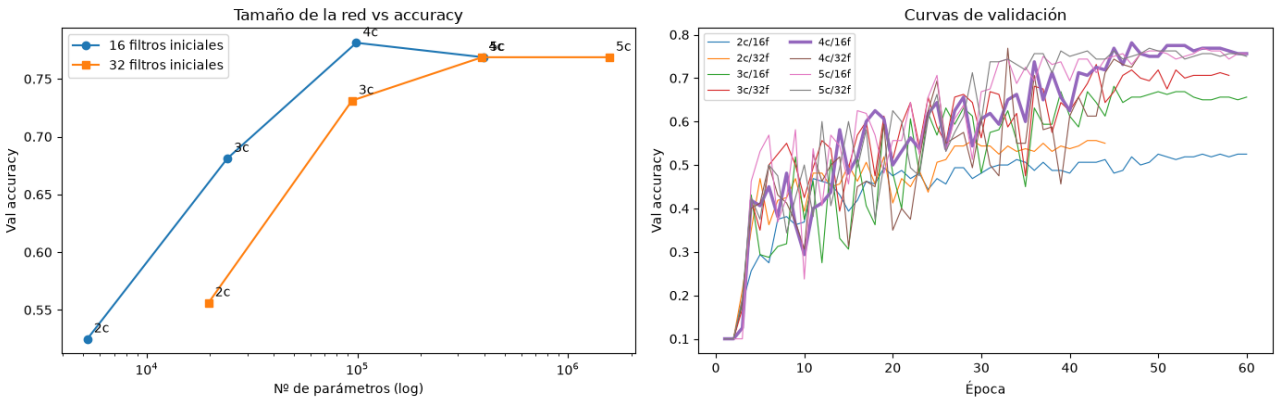


Figura 1. Accuracy de validación frente al nº de parámetros y curvas de validación de todas las configuraciones.

3. Task 2 – ResNet18 preentrenada

Se usa **ResNet18** preentrenada en ImageNet con la entrada RGB a 224×224 y normalización de ImageNet. Hay dos variantes:

• **Embeddings congelados + LogReg**: la red no se toca y se extrae el vector de 512 dimensiones del GAP. Encima se ajusta una regresión logística con búsqueda de C mediante 5-fold CV en train. Resultado: CV 0.667, **test 0.745**.

• **Fine-tuning completo**: se sustituye la capa final por una de 10 clases y se reentrena toda la red con lr 10^{-4} (20 épocas, paciencia 5), con la misma validación y augmentation que la CNN. La mejor época es la 8 (val 0.800), con **test 0.805**, el mejor resultado de esta partición. Converge en muchas menos épocas que la CNN desde cero (Figura 2), pero tiene 11.2M parámetros (113 veces más) y tarda 45 s frente a 13 s.

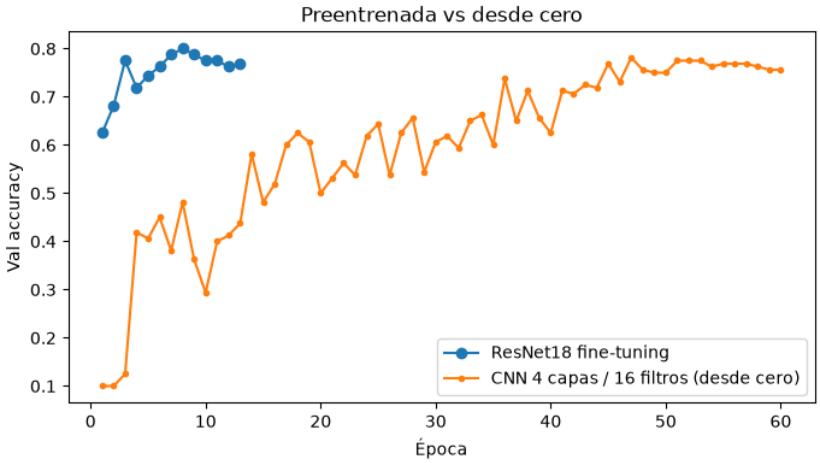


Figura 2. Accuracy de validación por época: fine-tuning vs CNN desde cero.

4. Todos los modelos y comparación con el Lab 1

La Tabla 2 recoge los resultados originales del Lab 1. Son la mejor accuracy de un 10-fold CV sobre todo el dataset, elegida entre varias combinaciones de hiperparámetros, así que no son comparables directamente con un test independiente. Por eso los modelos del Lab 1 se reentrenan con los mismos algoritmos y rejillas sobre el mismo 80% de train (5-fold CV para los hiperparámetros) y se evalúan en las mismas 200 canciones (Tabla 3). El mejor modelo de descriptores se elige por CV (la ANN, CV 0.730), no por test.

En el reentrenamiento destaca el Random Forest: era el mejor del Lab 1 en *features_30_sec* (0.794) y aquí se queda en 0.660 en test (CV 0.708). Las cifras del Lab 1 eran optimistas: cada fold entrenaba con más canciones (900 frente a 639) y se reportaba el máximo de la búsqueda de hiperparámetros evaluado en los mismos folds.

Modelo	GenreAll (50 features)	features_30_sec
Logistic Regression	0.767	0.737
k-NN	0.741	0.718
Decision Tree	0.566	0.606
Random Forest	0.735	0.794
ANN	0.796	0.752

Tabla 2. Resultados originales del Lab 1 (10-fold CV sobre todo el dataset).

Modelo	Familia	Test acc	Parámetros	Tiempo train (s)
ResNet18 fine-tuning	Preentrenado (fine-tuning)	0.805	11,181,642	44.9
CNN 4 capas / 16 filtros	CNN desde cero	0.780	98,922	13.0
ANN (Lab 1)	Descriptores Lab 1	0.755	-	6.5
ResNet18 congelada + LogReg	Preentrenado (congelado)	0.745	11,176,512	18.9
Logistic Regression (Lab 1)	Descriptores Lab 1	0.690	-	0.1
Random Forest (Lab 1)	Descriptores Lab 1	0.660	-	1.2
k-NN (Lab 1)	Descriptores Lab 1	0.630	-	0.3
Decision Tree (Lab 1)	Descriptores Lab 1	0.495	-	0.2

Tabla 3. Todos los modelos sobre el mismo test de 200 canciones (semilla 42).

5. Research questions

Q1. Do learned features beat hand-crafted descriptors?

En esta partición sí, pero por poco. En las mismas 200 canciones de test, la ResNet18 con fine-tuning (0.805) y la CNN desde cero (0.780) superan al mejor modelo de descriptores, la ANN (0.755), por 10 y 5 canciones respectivamente. Los demás modelos del Lab 1 quedan claramente por debajo: LogReg 0.690, Random Forest 0.660, k-NN 0.630 y árbol 0.495.

Que las features sean aprendidas no basta: tienen que aprenderse **para esta tarea**. Los embeddings congelados de ImageNet con LogReg (0.745) no llegan a la ANN sobre descriptores. ImageNet aprende formas y texturas de fotos, no patrones tiempo-frecuencia. En cambio, una CNN pequeña de 99k parámetros entrenada desde cero con solo 639 canciones alcanza o supera a 57 descriptores diseñados a mano.

Hay una salvedad importante: las diferencias son de 5-10 canciones y, como se ve en la Q5, al repetir con otras particiones los tres mejores modelos quedan empatados (~0.74-0.75). La conclusión honesta es que **las features aprendidas igualan a los descriptores, pero no los superan de forma clara** con un dataset de este tamaño.

Q2. Do CNNs and descriptor models make the same mistakes?

Solo en parte. Las tres matrices de confusión (Figura 3) comparten la estructura gruesa: classical y jazz se reconocen bien en los tres modelos (18-20 de 20), **rock está entre los géneros más difíciles** en todos (10-13 de 20) y **country ↔ rock** aparece entre los pares más confundidos de los tres. Esta parte de la estructura de similitud del Lab 1 es propia de la música: rock, country y pop comparten instrumentación (guitarras, batería, voz) y tempo.

El resto de errores sí depende de la representación. Las dos redes que ven el espectrograma confunden sobre todo **pop ↔ rock** y blues ↔ country, géneros con un timbre global parecido. La ANN sobre descriptores confunde **disco ↔ hiphop** (su par más frecuente) y pop ↔ reggae, y su género más difícil es disco (12 de 20); son géneros que coinciden en estadísticos de ritmo y energía (tempo, RMS, centroide) aunque su espectrograma sea distinto. Por tanto, parte de la estructura de similitud del Lab 1 se debe a los descriptores.

El solapamiento de errores (Tabla 4) lo confirma. Las dos CNNs fallan juntas en 25 canciones (Jaccard 0.43), pero cada CNN y la ANN solo comparten 18-23 errores (Jaccard 0.26-0.33). Si un oráculo eligiese en cada canción el modelo que acierta, ResNet18 + ANN llegaría a 0.910, 10 puntos más que el mejor modelo solo. Los dos enfoques son, por tanto, bastante complementarios.

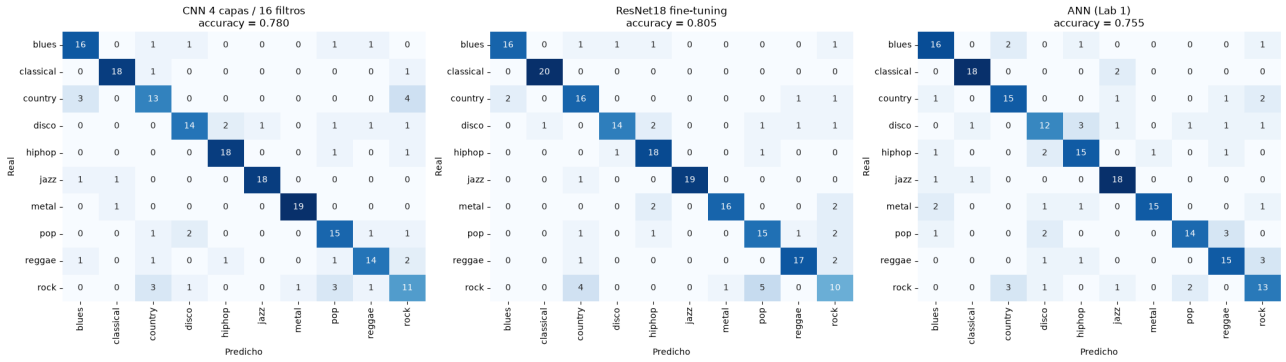


Figura 3. Matrices de confusión en test: CNN desde cero, ResNet18 con fine-tuning y ANN sobre descriptores.

A	B	Errores A	Errores B	Fallan ambos	Jaccard	Oráculo (acierta alguno)
CNN 4 capas / 16 filtros	ResNet18 fine-tuning	44	39	25	0.431	0.875
CNN 4 capas / 16 filtros	ANN (Lab 1)	44	49	23	0.329	0.885
ResNet18 fine-tuning	ANN (Lab 1)	39	49	18	0.257	0.910

Tabla 4. Solapamiento de errores entre pares de modelos (200 canciones de test).

CNN 4 capas / 16 filtros	ResNet18 fine-tuning	ANN (Lab 1)
country ↔ rock (7)	pop ↔ rock (7)	disco ↔ hiphop (5)
pop ↔ rock (4)	country ↔ rock (5)	country ↔ rock (5)
blues ↔ country (4)	metal ↔ rock (3)	reggae ↔ rock (3)
reggae ↔ rock (3)	disco ↔ hiphop (3)	pop ↔ reggae (3)
disco ↔ pop (3)	blues ↔ country (3)	disco ↔ pop (3)

Tabla 5. Pares de géneros más confundidos por cada modelo (nº de canciones, en ambos sentidos).

Q5. How much does one 80/20 split tell you?

Muy poco. Se repitió todo con 5 particiones distintas (semillas 0-4), manteniendo fija la configuración de cada modelo (Tabla 6, Figura 4). Las medias quedan prácticamente empatadas: ResNet18 fine-tuning 0.749 ± 0.061, ANN sobre descriptores 0.745 ± 0.045 y CNN desde cero 0.737 ± 0.018. La ordenación de la semilla 42 (fine-tuning > CNN > ANN) no se mantiene: en las diferencias pareadas frente a la ANN, el fine-tuning gana en 3 de 5 particiones (+0.004 de media) y la CNN en 2 de 5 (-0.008). Las dos diferencias son mucho menores que su desviación (~0.05), así que no son significativas.

La variabilidad entre particiones es grande. El fine-tuning va de 0.650 a 0.815, una diferencia de 33 canciones o 16 puntos, mientras que la diferencia entre los tres mejores modelos en la semilla 42 era de solo 10 canciones. La CNN pequeña es, junto a los embeddings congelados, el modelo más estable (rango de 9 canciones); el fine-tuning, con 11M parámetros y 639 canciones, es el que más depende de qué canciones caen en train, validación y test.

Hay además otra fuente de ruido: el entrenamiento en GPU no es determinista (cuDNN). En una ejecución anterior del mismo notebook, con la misma semilla, la configuración elegida fue 4 capas / 32 filtros con 0.830 en test, y en esta es 4 capas / 16 filtros con 0.780. Con 200 canciones de test, cada canción vale 0.5 puntos y diferencias menores de ~5 puntos no permiten afirmar que un modelo es mejor que otro.

La única conclusión robusta es que **los embeddings congelados de ImageNet son peores**: 0.682 ± 0.019, por debajo de la ANN en las 5 particiones (-0.063 de media).

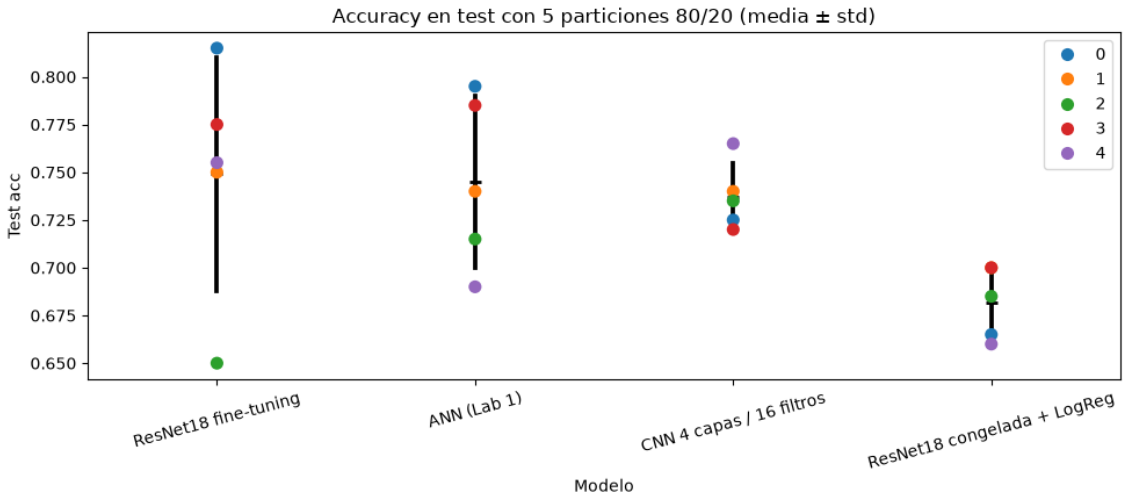


Figura 4. Accuracy en test de cada modelo con 5 particiones 80/20 distintas (media ± desviación típica).

	mean	std	min	max	rango (canciones)
ResNet18 fine-tuning	0.749	0.061	0.65	0.815	33
ANN (Lab 1)	0.745	0.045	0.69	0.795	21
CNN 4 capas / 16 filtros	0.737	0.018	0.72	0.765	9
ResNet18 congelada + LogReg	0.682	0.019	0.66	0.700	8

Tabla 6. Accuracy en test sobre 5 particiones.

	Diferencia media vs Lab 1	Std diferencia	Gana en (de 5)
CNN 4 capas / 16 filtros	-0.008	0.061	2
ResNet18 congelada + LogReg	-0.063	0.044	0
ResNet18 fine-tuning	0.004	0.047	3

Tabla 7. Diferencias pareadas frente a la ANN sobre descriptores (mejor modelo del Lab 1).

6. Conclusiones

Con los espectrogramas, una CNN pequeña entrenada desde cero (4 capas, 99k parámetros) y una ResNet18 con fine-tuning alcanzan un 78-80% en el test de la semilla 42. Es más que cualquier modelo del Lab 1 reentrenado en la misma partición (máximo 75.5%, ANN). Sin embargo, al promediar sobre 5 particiones los tres quedan en torno al 74-75% y las diferencias están dentro del ruido. Con ~800 canciones, los descriptores manuales siguen siendo competitivos y mucho más baratos de entrenar.

Los errores de las redes y de la ANN solo se solapan en parte: compartir instrumentación (rock/country/pop) confunde a todos, mientras que el ritmo y la energía confunden sobre todo a los descriptores (disco/hiphop). Un ensemble de CNN + descriptores es por tanto la mejora más prometedora: el oráculo indica un margen de hasta 10 puntos. Para afirmar que un modelo supera a otro hace falta repetir con varias particiones; una sola partición de 200 canciones no basta.